

Архком: Генерация кода с помощью LLM

Создана пользователем [Карбовничий Василий Юрьевич](#). Последнее обновление: [июн. 06, 2025](#) • Время чтения: 3 мин.

Название	Сервис генерации кода на основе LLM
Категория	Новая технология
Автор	@ Карбовничий Василий Юрьевич
Докладчик	@ Карбовничий Василий Юрьевич @ Копосов Александр Сергеевич

- Описание
- Сравнительный анализ
- Сравнение с GigaCode
- Хранение данных
- Безопасность
- Применение в компании


Анонс

Сервис для генерации кода на основе LLM

Описание

Сервис помогает разработчикам в генерации и автодополнении кода при разработке. Для IDE (Pycharm, VSCode, VSCodium) используются специальные плагины для интеграции с LLM. Плагин Continue используется для автодополнения кода, а плагины RooCode, DevovxGenie, ProхуAI для полноценной генерации и ответов на вопросы разработчика в чате. В качестве первоначальных моделей взяли Devstral от компании Mistral и DeepSeek Coder V2 от компании DeepSeek. Разворачивать будем в kubernetes кластере обучения (ML) на базе Ollama.

Схема работы:



Модель автодополнения - [autocomplete.sberned.ru](#)

Модель написания кода - [devassistant.sberned.ru](#)

Используемые ML Модели:

- Devstral-Small-2505
- DeepSeek-Coder-V2-Lite-Base

Используемые технологии:

- [Ollama \(API\)](#)

Плагины для Pycharm:

- [ProxyAI](#)
- [DevoxxGenie](#)
- [Continue](#)

Плагины для VSCode:

- [Continue](#)
- [RooCode](#)


Сравнительный анализ

ML Модели:

[Devstral](#) на данный момент лучшая opensource модель для SWE задач. Используется для полноценного написания блоков кода на разных языках. Лицензия Apache 2.0, Количество параметров 24b, размер 47Гб.



[DeepSeek](#) Coder V2 используется для автодополнения кода. Лицензия DeepSeek. Количество параметров 16b, размер 30Гб.



API сервер:

Выбрали [Ollama](#) потому что у большинства плагинов или библиотек есть готовые коннекторы к Ollama без дополнительной настройки. В другом случае рекомендуется использовать [vLLM](#) как более гибкую и перспективную технологию.

Плагины:

Выбор opensource плагинов способных работать с локальными LLM моделями небольшой и выбора практически не было. Будем искать оптимальные варианты в рамках пилота.

Сравнение с GigaCode

<https://gigacode.ru/>

GigaCode это закрытое решение с использованием LLM GigaChat от Сбер. Решение будет рентабельно если одна инсталляция сервиса сможет обслуживать более 30 разработчиков.

Надежность и масштабируемость

Масштабировать можно пока хватает видео ускорителей в кластере. Две модели занимают 60Гб VRAM на одной A100. Запросы осуществляются по http, за счёт чего можно управлять нагрузкой с помощью балансировщиков k8s. Полноценные нагрузочные испытания и потребление ресурсов будем проводить в процессе пилота.

Хранение данных

База данных отсутствует.

Безопасность

Авторизация, аутентификация и ролевая модель отсутствуют.

Ограничения по OVPN профиль разработчик / ops / кб, без бизнеса.

Применение в компании

Планируется использовать для помощи разработчикам в написании кода с помощью автодополнения, прямой генерации кода по запросу и ответов на вопросы по программированию.

Внедрение планируется постепенное:

- Тест на дата-инженеров внутри кластера ml при работе через vscode (1 неделя).
- Подготовка документации и создание инициативной группы (1 неделя).
- Тест на инициативной группе по всей компании на разработчиках разных стеков (3 месяца). Срезы по инициативной группе: по 2-3 человека от каждого стека и роли.
- Проверка успешности пилота, подготовка документации и презентации (2 недели).
- Релиз на всю компанию.

Критерий успешности пилота: рост производительности в пилотной группе не менее 8% за отчетный период (в объеме оценок закрытых задач).

Нет меток

2 Комментариев



Чернышев Евгений Михайлович

июн. 09, 2025

А можно будет это интегрировать с <https://github.com/olimorris/codecompanion.nvim> ?



Карбовнический Василий Юрьевич

июн. 10, 2025

Можно. Всё что поддерживает Ollama, может интегрироваться из коробки, у всех моделей интерфейс одинаковый.

Хотя для neovim мне рекомендовали <https://github.com/yetone/avante.nvim>